

Documentation

SenseNova AI API 文档

SenseNova 提供大模型 API 服务，覆盖文本对话、多模态图像理解、信息图生成、工具调用与流式响应等能力。

Base URL · 所有接口请求基于 <https://token.sensenova.cn/v1>
(OpenAI SDK 设置 base_url 时使用此地址)

快速开始

使用 SenseNova API 只需 3 步：

1. 注册账号并完成手机号验证
2. 在 [控制台](#) → [API Keys](#) 创建一枚 sk- 开头的密钥
3. 替换 OpenAI SDK 的 base_url 为 SenseNova 地址 (<https://token.sensenova.cn/v1>)，即可调用。

cURL

Python

Node.js

```
curl https://token.sensenova.cn/v1/chat/completions \  
-H "Authorization: Bearer {your key}" \  
-H "Content-Type: application/json" \  
-d '{  
  "model": "sensenova-6.7-flash-lite",  
  "messages": [{"role": "user", "content": "Hello!"}]  
'
```

 复制

鉴权

所有 API 请求必须在 HTTP Header 中携带 Bearer Token：

```
Authorization: Bearer {your key}
```

模型总览

SenseNova 6.7 Flash-Lite

面向真实工作流的轻量多模态智能体模型，支持文本对话与图像输入理解

调用次数限制

每5小时1500次

MODEL ID

sensenova-6.7-flash-lite

复制

SenseNova U1 Fast

基于 SenseNova U1 的加速版本，专供信息图 (Infographics) 生成

调用次数限制

每5小时1500次

MODEL ID

sensenova-u1-fast

复制

DeepSeek V4 Flash

DeepSeek 高性能对话模型，支持思考/非思考模式、256K 上下文、工具调用

调用次数限制

每5小时150次

MODEL ID

deepseek-v4-flash

复制

SenseNova 6.7 Flash-Lite

面向真实工作流的轻量多模态智能体模型，支持文本对话与图像输入理解。

- 轻量高效，兼顾效果、成本与落地性
- 原生多模态架构，支持图像输入理解（OCR、图表解读等）
- 办公场景增强，稳定支撑复杂长链路任务
- Token 效率更优，复杂任务成本更可控
- 上下文长度 256K tokens（最大输入 252K，最大输出 64K）

MODEL ID: sensenova-6.7-flash-lite

POST https://token.sensenova.cn/v1/chat/completions

纯文本对话

请求示例

cURL

Python

Node.js

```
curl https://token.sensenova.cn/v1/chat/completions \
-H "Authorization: Bearer {your key}" \
-H "Content-Type: application/json" \
-d '{
  "model": "sensenova-6.7-flash-lite",
  "messages": [
    { "role": "system", "content": "你是一个有用的助手。" },
    { "role": "user", "content": "介绍一下商汤科技。" }
  ],
  "stream": false
}'
```

 复制

图像输入（多模态理解）

SenseNova 6.7 Flash-Lite 支持通过 image_url 类型的 content 块传入图片进行内容理解与分析。

```
curl https://token.sensenova.cn/v1/chat/completions \
-H "Authorization: Bearer {your key}" \
-H "Content-Type: application/json" \
-d '{
  "model": "sensenova-6.7-flash-lite",
  "messages": [
    {
      "content": "你是一个说话客观公正的小助手",
      "role": "system"
    },
    {
      "role": "user",
      "content": [
        {
          "type": "text",
          "text": "你好"
        },
        {
          "type": "image_url",
          "url": "https://example.com/image.jpg"
        }
      ]
    }
  ]
}'
```

 复制

```
{
  "type": "image_url",
  "image_url": {
    "url": "https://example.com/image.jpg"
  }
}
```

工具调用 (Function Calling)

通过 `tools` 字段声明可用函数，模型会在需要时以 `tool_calls` 的形式返回调用请求。工具执行后，以 `role="tool"` 的消息把结果回传，再次请求即可获得最终答复。

请求示例

```
{
  "model": "sensenova-6.7-flash-lite",
  "messages": [
    { "role": "user", "content": "今天上海天气怎么样？" }
  ],
  "tools": [{
    "type": "function",
    "function": {
      "name": "get_weather",
      "description": "Get current weather of a city",
      "parameters": {
        "type": "object",
        "properties": {
          "city": { "type": "string" }
        }
      }
    }
  ]
}
```

 复制

模型返回 `tool_calls`

```
{
  "choices": [{
    "message": {
      "role": "assistant",
      "content": null,
      "tool_calls": [{
        "index": 0,
        "id": "call_abc123",
        "type": "function",
        "function": {
```

 复制

```
}}
```

回传工具结果

```
{
  "model": "sensenova-6.7-flash-lite",
  "messages": [
    { "role": "user", "content": "今天上海天气怎么样？ " },
    { "role": "assistant", "tool_calls": [ /* 上一步模型返回 */ ] },
    {
      "role": "tool",
      "tool_call_id": "call_abc123",
      "content": "{ \"temp\": 22, \"desc\": \"多云\"}"
    }
  ]
}
```

 复制

流式响应 (SSE)

设置 stream: true 后，响应 Content-Type 为 text/event-stream，每行以 data: {json} 推送一个 chunk，最后以 data: [DONE] 结束。

```
data:
{"id":"chatcmpl-...", "object":"chat.completion.chunk", "created":1713167890, "model":"sensenc
6.7-flash-lite", "choices":[{"index":0, "delta":
{"role":"assistant", "content":""}, "finish_reason":null}]}

data: {"id":"chatcmpl-...", "object":"chat.completion.chunk", "choices":
[{"index":0, "delta":{"content":"Hello"}, "finish_reason":null}]}

data: {"id":"chatcmpl-...", "object":"chat.completion.chunk", "choices":
[{"index":0, "delta":{"content":"! How can I help?"}, "finish_reason":null}]}

data: {"id":"chatcmpl-...", "object":"chat.completion.chunk", "choices":
[{"index":0, "delta":{}, "finish_reason":"stop"}], "usage":
{"prompt_tokens":12, "completion_tokens":8, "total_tokens":20}}
```

 复制

usage 仅在 stream_options.include_usage=true 时在最后一个 chunk 中返回。

请求参数

model	string	✓	-	固定为 sensenova-6.7-flash-lit
messages	array	✓	-	对话消息列表, $role \in \{\text{system}, \text{user}, \text{assistant}, \text{tool}\}$; content 为字符串或内容块数组 (图像输入时使用)
stream	boolean	—	false	是否以 SSE (text/event-stream 式返回
stream_options	object	—	{"include_usage": True}	仅 stream=true 生效。含 include_usage (boolean)
temperature	number	—	1	采样温度, 建议 [0, 2]
top_p	number	—	1	核采样, 范围 (0, 1]
max_tokens	integer	—	65535	最大生成 token 数, 范围 [1, 65536]
n	integer	—	1	生成回复数量, 范围 1-7
stop	string array	—	-	-
frequency_penalty	number	—	0	频率惩罚, [0,2]
presence_penalty	number	—	0	存在惩罚, [0,2]
reasoning_effort	string	—	"medium"	推理力度, 可选 low / medium high / none
tools	array	—	-	可用工具列表
tool_choice	string object	—	"auto"	工具选择策略: "auto" / "none" "required" 或指定工具
parallel_tool_calls	boolean	—	true	是否允许并行调用多个工具
seed	integer	—	-	随机种子 (Beta) , 范围 [0,99999999)

响应结构

```
{
  "id": "chatcmpl-8aBcD...",
  "object": "chat.completion",
  "created": 1713167890,
```

复制

```
"message": {
  "role": "assistant",
  "content": "商汤科技是一家领先的人工智能公司..."
},
"finish_reason": "stop"
}],
"usage": {
  "total_tokens": 128,
  "prompt_tokens": 64,
  "completion_tokens": 64
}
```

finish_reason 枚举

value	含义
stop	正常结束
length	达到 max_tokens 或上下文上限
tool_calls	模型选择调用工具
content_filter	内容被合规审核拦截

SenseNova U1 Fast

SenseNova U1 Fast 基于 SenseNova U1 的加速版本，专供信息图（Infographics）生成场景。

MODEL ID: sensenova-u1-fast

注意： U1 Fast 使用独立的图像生成接口 POST /v1/images/generations，不是 Chat Completions；不支持图像输入。

请求地址

POST https://token.sensenova.cn/v1/images/generations

复制

请求示例

- cURL
- Python
- Node.js

```
curl https://token.sensenova.cn/v1/images/generations \
-H "Authorization: Bearer {your key}" \
-H "Content-Type: application/json" \
```

力的可爱卡通风格（包含猫咪、拟人化表情等元素）。整体排版从左到右分为三个主要区块，分别介绍核心能力、工作流程和重要规则。

图表的左上角是醒目的主标题“信息图生成专家”，其下方紧跟副标题：“帮助用户将复杂信息转化为清晰易懂的视觉呈现”。

以下是图表中各区块的详细结构和全部文字内容：

1. 左侧区块：核心能力与专家提示

该区块主要列出了三项核心能力，并附带了一条专家提示。

核心能力（由上至下排列，每项均配有可爱的拟人化图标）：

1. 联网搜索功能：本消息源网络信息（图标为一个戴着猫耳、拿着放大镜的拟人化地

请求参数

字段	类型	必填	默认值	说明
model	string	✓	—	固定为 sensenova-u1-fast
prompt	string	✓	—	图像描述文本，最大token数为4096
size	string	—	2752x1536	图像尺寸，2K 分辨率常量 - 11 种 aspect ratio 对应的 [width, height] 1664x2496 2:3 2496x1664 3:2 1760x2368 3:4 2368x1760 4:3 1824x2272 4:5 2272x1824 5:4 2048x2048 1:1 2752x1536 16:9 1536x2752 9:16 3072x1376 21:9 1344x3136 9:21
n	integer	—	1	生成图片数量

响应结构

```
{
  "created": 1713167890,
  "data": [
    { "url": "https://cdn.sensenova.dev/gen/..." }
  ]
}
```

复制

DeepSeek 高性能对话模型，支持思考模式与非思考模式，上下文长度 256K tokens，最大输出 64K tokens，内置 JSON Output、Tool Calls等功能。

MODEL ID: deepseek-v4-flash

请求地址

POST <https://token.sensenova.cn/v1/chat/completions>

 复制

纯文本对话

cURL

Python

Node.js

```
curl https://token.sensenova.cn/v1/chat/completions \
-H "Authorization: Bearer {your key}" \
-H "Content-Type: application/json" \
-d '{
  "model": "deepseek-v4-flash",
  "messages": [
    { "role": "system", "content": "You are a helpful assistant." },
    { "role": "user", "content": "Hello!" }
  ],
  "stream": false
}'
```

 复制

思考模式

DeepSeek V4 Flash 默认启用思考模式，可通过 thinking 参数控制。

```
{
  "model": "deepseek-v4-flash",
  "messages": [
    { "role": "user", "content": "9.11 和 9.8 哪个更大? " }
  ],
  "thinking": {
    "type": "enabled",
    "reasoning_effort": "high"
  }
}
```

 复制

- type: "enabled" 启用思考模式, "disabled" 关闭思考模式
- reasoning_effort: "high" (默认) 或 "max" (复杂 Agent 场景)

思考模式下, 响应的 message 中会额外包含 reasoning_content 字段, 为模型的推理过程。

工具调用 (Function Calling)

```
{
  "model": "deepseek-v4-flash",
  "messages": [
    { "role": "user", "content": "杭州今天天气怎么样?" }
  ],
  "tools": [{
    "type": "function",
    "function": {
      "name": "get_weather",
      "description": "获取指定城市的当前天气",
      "parameters": {
        "type": "object",
        "properties": {
          "city": { "type": "string" }
        },
        "required": ["city"]
      }
    }
  ]
}
```

[复制](#)

JSON 输出

设置 response_format 启用 JSON 模式 (需在 prompt 中指示模型输出 JSON) :

```
{
  "model": "deepseek-v4-flash",
  "messages": [
    { "role": "system", "content": "请以 JSON 格式回答。" },
    { "role": "user", "content": "列出三种编程语言及其特点。" }
  ],
  "response_format": { "type": "json_object" }
}
```

[复制](#)

流式响应 (SSE)

设置 stream: true 后, 响应以 text/event-stream 形式推送, 最后以 data: [DONE] 结束。

请求参数

model	string	✓	—	固定为 deepseek-v4-flash
messages	array	✓	—	对话消息列表, role ∈ {system, user, assistant, tool}
thinking	object null	—	启用思考模式	{"type": "enabled"} 或 {"type": "disabled"}; reasoning_effort: "high" / "low"
stream	boolean	—	false	是否以 SSE 流式返回
stream_options	object	—	—	仅 stream=true 生效。含 include_usage (boolean)
temperature	float	—	1	采样温度, 范围 [0, 2]
top_p	float	—	1	核采样, 范围 (0, 1]
max_tokens	integer	—	65536	最大生成 token 数
stop	string array	—	—	停止序列
frequency_penalty	float	—	0	频率惩罚, [-2, 2]
presence_penalty	float	—	0	存在惩罚, [-2, 2]
response_format	object	—	—	{"type": "json_object"} 启用 JSON 输出模式
tools	array	—	—	可用工具列表
tool_choice	string object	—	auto	工具选择策略: none / auto / required 或指定工具

响应结构

复制

```
{
  "id": "chatcmpl-xxx",
  "object": "chat.completion",
  "created": 1714300000,
  "model": "deepseek-v4-flash",
  "choices": [{
    "index": 0,
    "message": {
      "role": "assistant",
      "content": "Hello! How can I help you today?",
      "reasoning_content": "用户打了招呼, 我应该友好地回应..."
    }
  ]
}
```

```
"usage": {
```

finish_reason 枚举

value	含义
stop	正常结束
length	达到 max_tokens 或上下文上限
tool_calls	模型选择调用工具
content_filter	内容被合规审核拦截

模型列表

列出当前可用的模型列表，返回每个模型的基本信息，包括能力、上下文长度、定价等。

请求

```
GET https://token.sensenova.cn/v1/models
```

复制

认证

```
Authorization: Bearer {your key}
```

请求示例

```
curl https://token.sensenova.cn/v1/models \
-H "Authorization: Bearer {your key}"
```

复制

响应结构

返回一个包含 data 数组的 JSON 对象，每个元素为一个 Model 对象。

```
{
  "data": [
    {
      "id": "sensenova-6.7-flash-lite",
      "hugging_face_id": "",
```

复制

```
"output_modalities": ["text"],
"quantization": "fp8",
"context_length": 262144,
"max_output_length": 65536,
"pricing": {
  "prompt": "0",
```

Model 对象字段说明

字段	类型	说明
id	string	模型唯一标识符，用于 API 调用时指定模型
name	string	模型名称（通常与 id 一致）
created	number	模型创建/发布时间（Unix 时间戳，秒）
description	string	模型功能的文字描述
input_modalities	array of string	支持的输入模态，可选值：text、image
output_modalities	array of string	支持的输出模态，可选值：text、image
context_length	number	最大上下文窗口长度（token 数）
max_output_length	number	单次请求最大输出长度（token 数）
quantization	string	模型量化精度（如 fp8）
pricing	object	定价信息
supported_sampling_parameters	array of string	模型支持的采样参数列表
supported_features	array of string	模型支持的功能特性
hugging_face_id	string	对应的 HuggingFace 模型 ID（如有）
openrouter	object	OpenRouter 路由信息，含 slug 字段
datacenters	array of string	模型部署的数据中心列表，含 country_code 字段

错误码

```
{
  "error": {
    "type": "invalid_request_error",
    "code": "3",
    "message": "invalid temperature, should in [0,2].",
  }
}
```

复制

HTTP 状态与错误类型

HTTP 状态码	错误类型 (type)	含义
400	invalid_request_error	请求参数不合法（缺失、超范围、格式错误等）
400	failed_precondition_error	前置条件不满足（编码失败、引擎不可用、安全检查未通过等）
403	permission_denied_error	不支持当前语言的请求等业务侧拒绝
404	not_found_error	模型 ID 不存在或已下线
408	canceled_error	客户端取消请求
429	quota_exceeded_error	速率或额度超限，建议指数退避重试
500	internal_server_error	服务器内部错误

文档章节

平台概览

